Universidade de Coimbra
Licenciatura em Engenharia e Ciência de Dados

Engenharia de Atributos

Meta 2

Beatriz Martins
2023210538
uc2023210538@student.dei.uc.pt

Laura Barreto
2023214375
uc2023214375@student.dei.uc.pt

Coimbra, 7 de Dezembro de 2025

1 Introdução

O objetivo da segunda meta do projeto é aprofundar técnicas de engenharia de atributos e avaliação de modelos para reconhecimento de atividades, incluindo SMOTE, embeddings, PCA, ReliefF e diferentes estratégias de divisão dos dados. Um classificador KNN é treinado e otimizado para comparar o desempenho entre múltiplos cenários e avaliar a capacidade de generalização do sistema.

2 Data Augmentation

Nesta primeira etapa, verificámos o desbalanceamento do conjunto de dados e usámos SMOTE para gerar novas amostras sintéticas.

2.1 Desbalanceamento entre Atividades (Alínea 1.1)

Ao observar a figura 1, podemos perceber que existe uma grande discrepância na distribuição das atividades, sendo que a primeira tem 5243 amostras e a sétima tem apenas 1593. Isto pode levar a que o KNN tenha uma maior dificuldade a classificar corretamente as atividades minoritárias, no caso de não ser aplicado nenhum método de balanceamento.

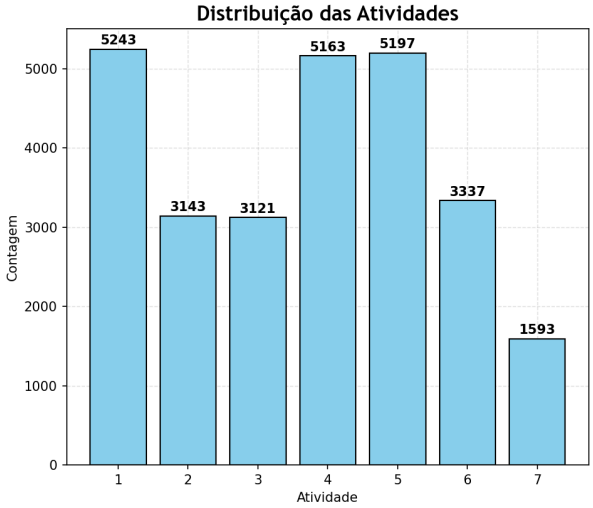

Figure 1: Distribuição de cada Atividade

2.2 SMOTE (Alíneas 1.2 e 1.3)

O objetivo nesta etapa é gerar 3 amostras sintéticas para a atividade 4 e o participante 3. Para isso criámos uma função que implementa este método de raiz. De forma a mostrar que as amostras foram geradas corretamente, criámos as visualizações que estão presentes nos gráficos da figura 2, em que os novos pontos estão em formato de "x" para serem facilmente distinguíveis.

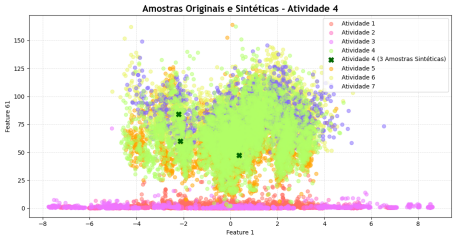

(a) Dados de todos os participantes

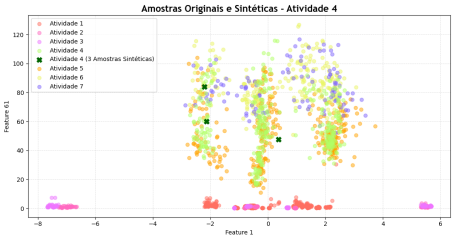

(b) Dados apenas do participante 3

Figure 2: Três amostras sintéticas geradas pelo SMOTE nos dados do participante 3 na atividade 4

É possível perceber que as amostras geradas situam-se perto dos pontos da atividade 4 do participante 3 (pontos a verde), o que revela a interpolação que aconteceu ao gerar as três amostras sintéticas. Também podemos perceber pela figura 2 (a), que mostra o conjunto de dados de todos os participantes, que as features 1 e 61 parecem conseguir distinguir visivelmente bem as atividades 1, 2 e 3 (mais contidas na linha y = 0) das restantes, que se encontram mais dispersas no resto do gráfico.

3 Embeddings

Nesta etapa, adicionámos ao ficheiro mainActivity.py o código necessário para extrair também os embeddings na função que já extraía as features por janela. Posteriormente, guardámos três ficheiros CSV separados: um com os embeddings, outro com as features e um terceiro com o vetor das atividades correspondentes. Esta abordagem permitiu desacoplar as duas metas, tornando o código mais organizado e fácil de compreender.

4 Data Splitting Strategy

Nesta etapa, foram usados dois tipos de estratégias de data splitting: within subject e between subjects. Ao experimentar cada uma delas, foi-nos possível evidenciar as diferenças entre as duas e comparar os seus resultados.

A estratégia do TVT within subject faz com que o modelo teste em participantes que já viu e nos quais já treinou, o que o torna um pouco enviesado e muito pouco generalizável. Já a abordagem do TVT between subjects permite que o modelo teste em participantes que nunca antes viu, levando-o a ser mais robusto e preparado para classificar corretamente novos participantes reais.

5 Model Learning

Nesta etapa foi usado o modelo KNN para classificar a atividade de cada amostra de teste, com base nas atividades dos seus k vizinhos mais próximos nos dados de treino.

5.1 Implementação do Modelo e Resultados (Alíneas 4.1 e 4.2)

Implementámos o modelo KNN manualmente, sendo muito importante normalizar sempre os dados primeiro, pois ele é sensível à escala das features ao calcular as distâncias entre pontos. Para este modelo, foi utilizada a biblioteca sklearn para obter melhor performance. De forma a representar os resultados deste modelo, foi usado *"classification_report"* da mesma biblioteca, uma vez que já contém todas as métricas (precision, recall, accuracy e F1-score) e ainda a Matriz de Confusão, em que podemos analisar o número de falsos negativos (FN), falsos positivos (FP), verdadeiros positivos (TP) e verdadeiros negativos (TN) de todas as atividades.

6 Evaluation

Nesta parte, iremos mostrar todo o processo de avaliação do modelo desde tunning do hiperparâmetro k a resultados e testes estatísticos.

6.1 Otimização de Hiperparâmetros

Foram realizados 31 trials, cada um sujeito a um split novo, de forma a obter distribuições de F1 resultantes nos dados de teste dos 6 cenários diferentes (Features/Embeddings, Features/Embeddings com PCA e Features/Embeddings com ReliefF). Após os dois splits de cada trial, aplica-se o PCA e o ReliefF nas features e embeddings nos três conjuntos: treino, validação e teste. Para tal, usamos sempre o mesmo scaler e conjunto de vetores próprios (no caso do PCA) e as mesmas colunas (no caso do ReliefF) obtidas nos dados de treino, para os restantes conjuntos. Posteriormente, foram testados vários valores de k no conjunto de validação (entre 1 e 15, de dois em dois) e o que obteve melhor resultado foi usado posteriormente no KNN para o conjunto de teste.

6.2 Análise de Resultados

Decidimos mostrar só os resultados dos melhores modelos de cada split que são as Features com ReliefF (no caso do split entre participantes) e as Features com o PCA (no caso do split por participante), como mostraremos na secção a seguir.

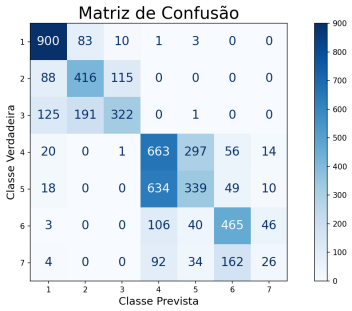

(a) Matriz de confusão

Relatório de classificação:

	precision	recall	f1-score	support
1	0.78	0.90	0.84	997
2	0.60	0.67	0.64	619
3	0.72	0.50	0.59	639
4	0.44	0.63	0.52	1051
5	0.47	0.32	0.38	1050
6	0.64	0.70	0.67	660
7	0.27	0.08	0.13	318
accuracy			0.59	5334
macro avg	0.56	0.55	0.54	5334
weighted avg	0.58	0.59	0.57	5334

(b) Classification report

Figure 3: Resultados das features com PCA na primeira Trial do split between participant

No split por participante, podemos observar que o modelo tem mais dificuldade na distinção entre as atividades 2 (Sit) e 3 (Sit and Talk) e entre as atividades 4 (Walk) e 5 (Walk and Talk), dado que são atividades bastante semelhantes. A atividade 5 possui mais falsos negativos do que falsos positivos, daí a sua recall ser mais baixa do que a precision, sendo a maioria dos falsos negativos atribuídos, pelo KNN, à atividade 4, quando na verdade eram a atividade 5. Também podemos reparar que a atividade 6 (Climb Stair (up/down)) é confundida com as atividades 4 (Walk) e 7 (Walk and Talk). A atividade 7 é a pior a ser classificada, obtendo um F1-score mais baixo de 13%. De 318 amostras, o KNN só detetou 26 delas, sendo a atividade 7 muitas vezes confundida com as atividades 4 e 6. A atividade 1 foi a melhor classificada, resultando num valor de F1-score de 84%, sendo que de 997 amostras detetou 900 corretamente. É importante relembrar que esta atividade foi, provavelmente, a que teve mais exemplos de treino por ser a classe maioritária, como vimos na figura 1. Isto pode ter levado a que o modelo tenha tido melhores resultados para esta atividade. Já a atividade 7 por ser minoritária obteve valores mais baixos com apenas 13% de F1-score.

Contudo, observamos que este modelo apresentou um desempenho bastante razoável neste trial, alcançando uma accuracy de 59%, mesmo apresentando um problema claro de desbalanceamento.

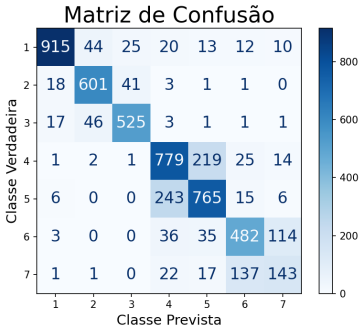

(a) Matriz de confusão

Relatório de classificação:

	precision	recall	f1-score	support
1	0.95	0.88	0.92	1039
2	0.87	0.90	0.88	665
3	0.89	0.88	0.89	594
4	0.70	0.75	0.73	1041
5	0.73	0.74	0.73	1035
6	0.72	0.72	0.72	670
7	0.50	0.45	0.47	321
accuracy			0.78	5365
macro avg	0.76	0.76	0.76	5365
weighted avg	0.79	0.78	0.78	5365

(b) Classification report

Figure 4: Resultados das features com ReliefF na primeira Trial do split within participant

Já no split within-subjects, testando em participantes que já foram treinados à priori, obtemos resultados bastante melhores, como seria de esperar. Obtemos uma accuracy de 78% e só a classe 7 é que apresenta um valor de F1-score abaixo de 50%, com valor de 47%. No entanto, continua bastante presente a dificuldade de distinguir entre as atividades 4 e 5, e 6 e 7.

6.3 Testes de Hipóteses

Após obtermos as distribuições do F1-score para os 12 cenários, verificámos se seguiam ou não uma distribuição normal, de forma a determinar quais os testes estatísticos adequados. Constatámos que nenhuma das distribuições apresentava normalidade, como se pode observar na Figura 5.

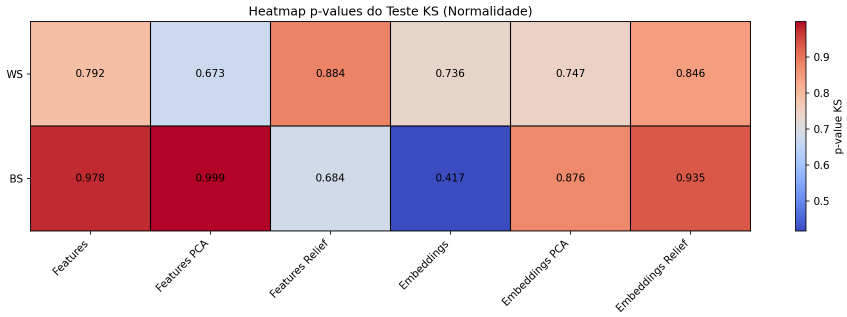

Figure 5: Averiguar normalidade de distribuições dos F1-scores dos seis cenários nos dois splits

Assim, aplicámos o teste da ANOVA emparelhado para verificar se existia pelo menos uma distribuição significativamente diferente das restantes. Confirmou-se que, em ambas as variantes de splits, há pelo menos uma distribuição com diferenças estatisticamente significativas, como ilustrado na Figura 6.

```
--- ANOVA EMPARELHADA NOS CENÁRIOS DO SPLIT WS: ---
p-valor = 0.0000 → diferenças significativas em pelo menos um cenário.

--- ANOVA EMPARELHADA NOS CENÁRIOS DO SPLIT BS: ---
p-valor = 0.0000 → diferenças significativas em pelo menos um cenário.
```

Figure 6: Teste ANOVA nos seis cenários de cada split

Posteriormente, ainda aplicámos o teste T-test emparelhado, nos pares das distribuições de F1-scores dos seis cenários de cada split, para descobrirmos exatamente quais são signitivamenete diferentes. Foi possível concluir que apenas as features com ReliefF e os embeddings com PCA não apresentam diferenças significativas como é visível na imagem 7 (b), e como iremos visualizar nos boxplots da figura 8.

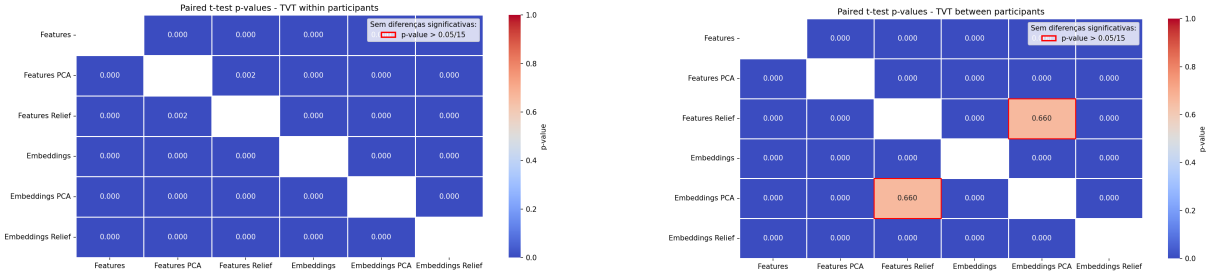

(a) TVT entre participantes

(b) TVT por participante

Figure 7: P-values dos testes T-test nas distribuições F1 nos seis cenários dos dois splits

Decidimos também visualizar as distribuições através de boxplots, já que, desta forma conseguimos visualmente perceber qual o cenário que teve valores de F1-score mais altos e que foi o melhor, já que todos os pares de cenários são diferentes, como confirmamos anteriormente no caso do split entre participantes.

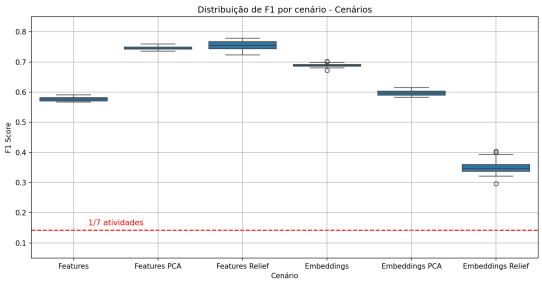

(a) TVT entre participantes

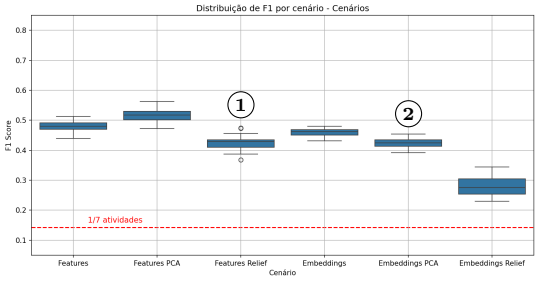

(b) TVT por participante

Figure 8: Distribuições dos F1 em 31 trials nos seis cenários dos dois tipos de splits

O split within participant apresentou, como seria de esperar, resultados superiores ao split between participant, uma vez que o primeiro avalia o modelo usando indivíduos que também estão presentes no treino, o que introduz enviesamento e reduz a capacidade de generalização.

Neste split, observamos que o cenário das Features com ReliefF obteve o melhor desempenho: apresenta a média mais elevada e uma variância reduzida. Como este cenário é também estatisticamente diferente de todos os restantes, concluímos que constitui a abordagem com melhor performance.

No caso do split between participant, identificamos as Features com PCA como o cenário com o melhor desempenho, dado que apresenta a média mais alta e uma variância ligeiramente baixa. Sendo estatisticamente diferente de todos os outros cenários, confirma-se como a melhor abordagem neste contexto.

Adicionalmente, observámos que as distribuições das Features com ReliefF (1) e dos Embeddings com PCA (2) são visivelmente semelhantes, o que está de acordo com o facto de não existirem diferenças estatisticamente significativas entre estes cenários, como verificámos na figura 7 (b).

Por fim, destacamos que os Embeddings com ReliefF apresentam o desempenho mais baixo em ambos os tipos de split.

7 Deployment

Para o deployment usámos o split between participant e treinamos o melhor modelo (Features com PCA) no conjuntos de treino mais validação, testando vários valores de k no teste. O k com valor mais elevado de F1-score é escolhido para posteriormente ser usado para deployment. Os conjuntos de treino, validação e teste passam a corresponder ao treino final usado para o deployment. Já sobre o array, primeiro extraímos as features nessa janela, aplicamos o PCA com o "scaler" e o "pca" obtido apenas no conjunto de treino mais validação, e prevemos as atividades de cada amostra com base no conjunto total de dados. É importante referir que, antes de aplicar o KNN, também normalizamos os dados de entrada com base nas amostras de treino, e por fim a função retorna a previsão da atividade presente na janela.

8 Extras

Com o intuito de ir mais além e tentar obter melhores resultados, experimentámos testar os seguintes extras, no split between participant:

1. SMOTE Borderline
2. KNN distance-based
3. Fisher Score

Realizámos exatamente o mesmo processo anterior, mas, desta vez aplicámos o SMOTE Borderline para balancear apenas os conjuntos de treino (tanto o treino usado na fase de tuning do k, como no conjunto de treino e validação resultante da etapa de retraining). Utilizámos também o KNN com ponderação pela distância, que atribui maior peso aos vizinhos mais próximos da amostra a classificar.

Para além dos seis cenários já avaliados, incluímos ainda o Fisher Score, aplicado tanto às features como aos embeddings. Esta abordagem é rápida, mantém a interpretabilidade e beneficia da utilização do SMOTE Borderline, pois calcula a separação entre classes de forma equilibrada. Assim, evita atribuir pontuações elevadas a features que distinguem bem as classes maioritárias mas mal as minoritárias.

Por fim obtivémos as distribuições de F1-score nestes oito cenários e verificámos que todas as distribuições seguem uma distribuição normal, como é percetível na figura 9.

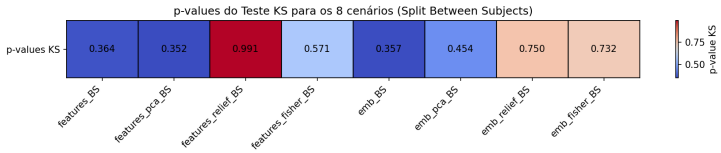

Figure 9: Normalidade dos oito cenários

Portanto foram aplicados os teste paramétricos emparelhados ANOVA e T-test apenas às features, até porque ao aplicar o SMOTE às Features e Embeddings separadamente, estes conjuntos deixam de estar emparelhados. Os resultados destes dois testes nas Features estão presentes nas figuras 10 e 11 (b).

```
--- ANOVA EMPARELHADA NAS FEATURES DO SPLIT BS: ---
p-valor = 0.0000 → diferenças significativas em pelo menos um cenário.
```

Figure 10: P-valor do teste ANOVA emparelhada nas features

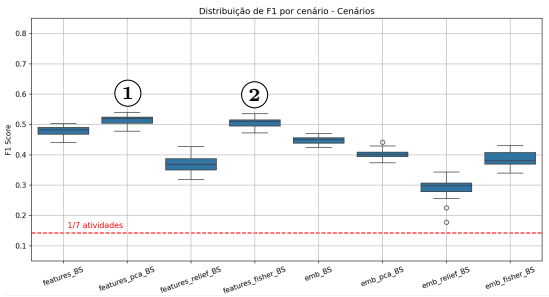

(a) Distribuições dos F1-score

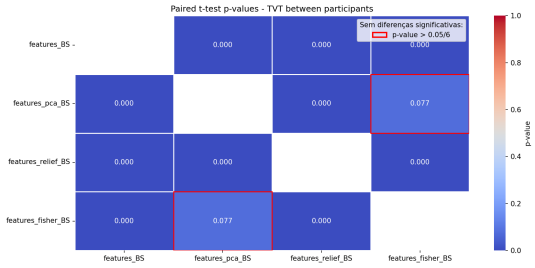

(b) T-test emparelhado apenas nas Features

Figure 11: Distribuições F1-score nos oito cenários e p-values do T-test nas Features

No caso dos Embeddings é percetível que, sem nenhum método de redução de dimensionalidade, obtém-se uma distribuição mais alta e um melhor desempenho comparando com os restantes.

Já no caso das Features verificou-se um empate entre o PCA (1) e o Fisher Score (2), cujas distribuições não diferem significativamente, como se observa na figura 11 (b). Os Embeddings com ReliefF continuam a apresentar uma distribuição mais baixa.

Por fim, também analisámos a matriz de confusão e o classification report da primeira trial das Features com o PCA usando estes extras descritos anteriormente.

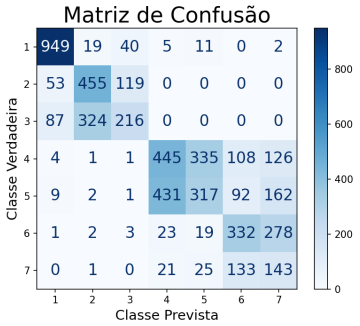

(a) Matriz de confusão

```
Relatório de classificação:
              precision    recall  f1-score   support

           1       0.86      0.92      0.89      1026
           2       0.57      0.73      0.64       627
           3       0.57      0.34      0.43       627
           4       0.48      0.44      0.46      1020
           5       0.45      0.31      0.37      1014
           6       0.50      0.50      0.50       658
           7       0.20      0.44      0.28       323

    accuracy                           0.54      5295
   macro avg       0.52      0.53      0.51      5295
weighted avg       0.55      0.54      0.54      5295
```

(b) Classification report

Figure 12: Resultados das features com PCA na primeira Trial do split between participant

Concluímos que continua a existir o problema na distinção das atividades 2 com a 3; 4 com a 5; 6 com a 7; e 7 com a 6, 5 e 4. No entanto parece-nos que, aplicando o SMOTE Borderline, conseguimos

classificar a atividade 7 ligeiramente melhor, pois o valor de F1-score desta atividade é de 28% já sem o uso de SMOTE obtivemos um valor de apenas 13% nesta atividade na figura 3 (b) na primeira trial. No entanto, como estes cenários estão aplicados em splits distintos não podemos dizer com certeza que isto se trata de uma verdade absoluta, porque estão em circunstâncias diferentes, logo as seus resultados não são comparáveis. Todavia é visível que com os extras, o modelo tentou detetar mais a atividade 7 dando até bastantes falsos positivos, daí termos uma recall superior de 44% e uma precision inferior de apenas 20%. Por fim, também podemos reparar que a atividade 4 já não é tão confundida com as atividades 6 e 7 dando menos falsos negativos do que os representados na figura 3 (a).